



**دانشگاه صنعتی امیرکبیر**  
(پلی تکنیک تهران)

دانشکده ریاضی و علوم کامپیوتر

استاد درس: دکتر مهدی قطعی

آذر ۱۴۰۴

**تمرین پنجم**  
درس داده‌کاوی محاسباتی

## موضوع پروژه: انتخاب ویژگی با استفاده از مقادیر تکین (SVD) در برابر روش‌های کلاسیک

### هدف از انجام پروژه

هدف از این پروژه، عبور از کاربرد «جعبه سیاه» الگوریتم‌ها و درک ریاضیاتی این مسئله است که چگونه تجزیه مقادیر تکین (SVD) می‌تواند ساختار پنهان داده‌ها را آشکار کند. در این تمرین، شما به جای استفاده صرف از توابع آماده، با تحلیل مستقیم ماتریس‌های  $U$ ،  $\Sigma$  و  $V^T$ ، مهم‌ترین ویژگی‌های یک مجموعه داده صنعتی را شناسایی کرده و آن را با روش‌های کلاسیک (مانند RFE) مقایسه می‌کنید. اهداف اصلی عبارتند از:

- درک نقش ماتریس بردارهای تکین راست ( $V^T$ ) در تعیین سهم هر ویژگی اولیه.
- یادگیری نحوه وزن‌دهی به ویژگی‌ها با استفاده از مقادیر تکین ( $\Sigma$ ).
- مقایسه پایداری (Stability) روش‌های جبری (SVD) در برابر روش‌های تکراری (Wrapper/RFE) در حضور نویز.
- مصورسازی هندسی ویژگی‌ها با استفاده از نمودار بارگذاری (Loading Plot).

## مفاهیم و مهارت‌هایی که دانشجو خواهد آموخت

- پیاده‌سازی و مقایسه روش‌های کلاسیک انتخاب ویژگی شامل RFE و Variance Threshold.
- استفاده خلاقانه از تجزیه مقادیر تکین (SVD) برای انتخاب ویژگی (نه صرفاً استخراج).
- تحلیل ماتریس بارگذاری (Loadings) برای تفسیر فیزیکی سنسورهای مهم.
- تحلیل حساسیت الگوریتم‌ها نسبت به داده‌های پرت (Outliers) و نویز.
- کار با داده‌های صنعتی واقعی (نامتوازن و ابعاد بالا).

## تعاریف مفاهیم پایه

تجزیه مقادیر تکین (SVD)<sup>۱</sup> هر ماتریس داده  $X$  (با ابعاد  $n \times m$ ) را می‌توان به صورت  $X = U\Sigma V^T$  تجزیه کرد. در اینجا:

- ماتریس  $\Sigma$  شامل مقادیر تکین  $(\sigma_i)$  است که «انرژی» یا اهمیت هر مؤلفه را نشان می‌دهد.
- ماتریس  $V^T$  (با ابعاد  $m \times m$ ) شامل بردارهای تکین راست است. هر سطر از  $V^T$  متناظر با یک مقدار تکین است و نشان می‌دهد که ویژگی‌های اولیه  $(x_1, \dots, x_m)$  با چه وزن‌هایی ترکیب شده‌اند تا آن مؤلفه را بسازند.

انتخاب ویژگی با SVD (SVD Feature Ranking)<sup>۲</sup> برخلاف PCA که ویژگی‌های جدید می‌سازد (استخراج)، ما می‌توانیم از SVD برای انتخاب ویژگی‌های قدیمی استفاده کنیم. اگر ویژگی  $j$  در بردارهای تکین اول (که  $\sigma$  بزرگی دارند) ضریب بزرگی داشته باشد، یعنی آن ویژگی نقش مهمی در ساختار اصلی داده دارد.

<sup>۱</sup> Singular Value Decomposition  
<sup>۲</sup> SVD Ranking

## تعریف پروژه و ساختار اجرایی آن

پروژه باید به صورت گام به گام در محیط Google Colab و با زبان Python اجرا شود.

### بخش اول: آماده‌سازی داده‌های صنعتی (SECOM)

دیتاست: از دیتاست UCI SECOM (ساخت نیمه‌هادی) استفاده کنید. این داده‌ها دارای صداها، سنسور، نویز زیاد و مقادیر گم‌شده هستند.

- مرحله ۱.۱: دیتاست را بارگذاری کنید. ستون‌های ثابت (واریانس صفر) را حذف کنید و NaNها را با روش Median Imputation پر کنید.

- مرحله ۲.۱: داده‌ها را نرمال‌سازی کنید (StandardScaler). (Hint: SVD is scale-sensitive. Without standardization, sensors with large units will artificially dominate the singular values.)

### بخش دوم: روش‌های کلاسیک (مبنای مقایسه)

- مرحله ۱.۲ - روش فیلتر: با استفاده از Mutual Information (تابع mutual\_info\_classif)، تعداد ۲۰ ویژگی برتر را انتخاب کنید.

- مرحله ۲.۲ - روش پوششی (RFE): با استفاده از RandomForest و الگوریتم RFE، تعداد ۲۰ ویژگی برتر را بیابید. گزارش: زمان اجرای دقیق این مرحله را ثبت کنید.

### بخش سوم: روش جبری (رتبه‌بندی با مقادیر تکین)

این بخش قلب ریاضی تمرین است. شما نباید از توابع آماده انتخاب ویژگی استفاده کنید، بلکه باید الگوریتم را بسازید.

- مرحله ۱.۳ - تجزیه: با استفاده از `numpy.linalg.svd`، ماتریس‌های  $U$ ,  $\Sigma$ ,  $V^T$  را محاسبه کنید.

- مرحله ۲.۳ - تحلیل ریاضی (امتیازدهی): یک تابع امتیازدهی (Score Function) برای هر ویژگی اولیه  $j$  تعریف کنید. ایده: ویژگی  $j$  مهم است اگر در  $k$  بردار تکین اول، وزن زیادی داشته باشد.

فرمول پیشنهادی برای پیاده‌سازی:

$$Score_j = \sum_{i=1}^k \sigma_i^2 \cdot |V_{ij}|$$

(Hint: Here,  $V_{ij}$  is the absolute coefficient of feature  $j$  in the  $i$ -th singular vector. We weight it by  $\sigma_i$  because vectors with small singular values represent noise.)

- مرحله ۳.۳ - انتخاب: بر اساس امتیازهای محاسبه شده، ۲۰ ویژگی برتر را انتخاب کنید.

### بخش چهارم: تحلیل هندسی و پایداری

این بخش برای سنجش عمق درک شما از هندسه داده طراحی شده است.

- مرحله ۱.۴ - نمودار بارگذاری (Loadings Plot): برای دو مؤلفه اول ( $PC1$  و  $PC2$ )، نمودار پراکندگی ضرایب  $V$  را رسم کنید. هر نقطه در این نمودار یک «ویژگی» است. آیا می‌توانید خوشه‌هایی از سنسورها که رفتار مشابهی دارند را تشخیص دهید؟ (ویژگی‌هایی که در یک جهت بردار کشیده شده‌اند).
- مرحله ۲.۴ - تست پایداری (Stability Test): ۵٪ نویز تصادفی به داده‌های اصلی اضافه کنید. مجدداً ۲۰ ویژگی برتر را با روش RFE و روش SVD انتخاب کنید. سوال: لیست ویژگی‌های منتخب کدام روش تغییر کمتری کرد؟ (روش‌های جبری معمولاً در برابر نویز پایدارترند).

### بخش پنجم: مقایسه نهایی

یک مدل Logistic Regression ساده را روی سه زیرمجموعه داده (۲۰ ویژگی MI، ۲۰ ویژگی RFE، ۲۰ ویژگی SVD) آموزش دهید.

۱. جدول مقایسه: دقت (Accuracy)، F1-Score و «زمان انتخاب ویژگی» را مقایسه کنید.

۲. تحلیل همپوشانی: نمودار ون (Venn Diagram) رسم کنید که نشان دهد چند درصد اشتراک بین روش SVD و RFE وجود دارد.

۳. نتیجه‌گیری: برای یک کاربرد صنعتی که نیاز به تفسیرپذیری و سرعت بالا دارد، کدام روش را پیشنهاد می‌کنید؟

## نکات پایانی و دستورالعمل ارسال

- نیاز است که گزارش ارسالی حتما در قالب خواسته شده باشد.
- در صورت هرگونه سوالی در گروه بپرسید.
- ذکر منابع اجباری است.
- نیازی به ریز شدن در مطالب نیست، بیان مسئله و مشکل، و چگونگی رفع مسئله با روش خوانده شده کافی است.
- فایل گزارش خود را به صورت PDF بفرستید.
- تمامی کدها، داده‌ها و فایل‌های پروژه را در یک مخزن GitHub Repository بارگذاری کنید، و لینک دسترسی به ریپازیتوری را در انتهای گزارش خود قرار دهید. مخزن باید به صورت Public تنظیم شود تا قابل مشاهده باشد.
- به یاد داشته باشید هدف این تمرین، درک اهمیت این درس، و آشنایی با برخی موضوعات است که در آینده بسیار با آن‌ها برخورد خواهید داشت، ملاک نمره حجم گزارش ارسالی نخواهد بود.

---

موفق باشید.