



دانشگاه صنعتی امیرکبیر  
(پلی‌تکنیک تهران)  
دانشکده ریاضی و علوم کامپیوتر

پروژه پنجم درس داده کاوی محاسباتی  
علوم کامپیوتر، هوش مصنوعی و محاسبات نرم

نشرده سازی مدل های عمیق با تجزیه رتبه پایین و ارتقای کیفیت صنعتی

نگارش  
هومن ذوالفقاری

استاد راهنمای  
دکتر مهدی قطعی

۱۴۰۴ دی

## تعهدنامه اصالت اثر



اینجانب هومن ذوالفقاری متعهد می‌شوم که مطالب مندرج در این پایان نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی اساتید دانشگاه صنعتی امیرکبیر بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روای متعارف ارجاع و در فهرست منابع و مأخذ ذکر گردیده است. این پایان نامه قبلاً برای احراز هیچ مدرک همسطح یا بالاتر ارائه نگردیده است.

در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان نامه متعلق به دانشگاه صنعتی امیرکبیر می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان نامه بدون موافقت کتبی دانشگاه صنعتی امیرکبیر ممنوع است.

نقل مطالب با ذکر مأخذ بلامانع است.

در صفحه تعهدنامه اصالت اثر، در قسمت بالا سمت چپ، تاریخ دفاع خود را جایگزین تاریخ نوشته شده کنید.

همچنین در صفحه تعهدنامه اصالت اثر، در خط اول، نام و نام خانوادگی خود را به صورت کامل با نام و نام خانوادگی نمونه، جایگزین کنید. در انتهای متن تعهد، در قسمت امضا نیز باید نام و نام خانوادگی کامل خود را وارد نماید.

هومن ذوالفقاری

امضا

## چکیده

مدل‌های یادگیری عمیق علی‌رغم دقت بالا، معمولاً دارای تعداد زیادی پارامتر و هزینه محاسباتی قابل توجهی هستند که استفاده از آن‌ها در محیط‌های عملیاتی و صنعتی محدود می‌کند. در این پژوهش، از تکنیک‌های پیشرفته جبر خطی، بهویژه تجزیه مقادیر منفرد(SVD)، برای فشرده‌سازی لایه‌های یک شبکه عصبی عمیق استفاده شده است. بدون تغییر در معماری کلی مدل، لایه‌های حجیم به تقریب‌های رتبه پایین تبدیل شده‌اند. نتایج نشان می‌دهد که با کاهش قابل توجه تعداد پارامترها، افت دقت ناچیز بوده و با استفاده از تنظیم دقیق(Fine-tuning)， حتی بهبود دقت نیز حاصل می‌شود. همچنین، تأثیر فشرده‌سازی بر سرعت استنتاج در محیط CPU بررسی شده است.

صفحه

فهرست مطالب

Contents

|    |                                    |
|----|------------------------------------|
| ۱  | چکیده                              |
| ۲  | فصل اول مقدمه                      |
| ۳  | فصل دوم تحلیل طیفی وزن های مدل     |
| ۶  | فصل سوم پیاده سازی عملی فشرده سازی |
| ۸  | فصل چهارم ارزیابی دقت و سرعت       |
| ۱۰ | فصل پنجم سوالات تحلیلی             |
| ۱۳ | فصل ششم نتیجه گیری                 |
| ۱۵ | منابع و مراجع                      |

## فصل اول مقدمه

## مقدمه

لینک کد در گیتهاب:

<https://github.com/hoomanzolfaghari84/Data-Mining-Course.git>

با گسترش کاربردهای صنعتی یادگیری عمیق، نیاز به مدل‌هایی با مصرف حافظه کمتر و سرعت استنتاج بالاتر بیش از پیش احساس می‌شود. بسیاری از شبکه‌های عصبی عمیق دارای افزونگی پارامتری هستند و وزن‌های آن‌ها را می‌توان با تقریب‌های کمرتبه نمایش داد. تجزیه مقادیر منفرد (SVD) یکی از ابزارهای قدرتمند جبر خطی است که امکان تحلیل طیفی وزن‌ها و فشردهسازی مؤثر لایه‌های خطی را فراهم می‌کند.

هدف این پروژه، بررسی عملی امکان فشردهسازی یک مدل از پیش آموزش‌دیده بدون تغییر معماری کلی آن، و ارزیابی اثر این فشردهسازی بر دقت، تعداد پارامترها و سرعت استنتاج است.

## **فصل دوم**

### **تحلیل طیفی وزن های مدل**

## تحلیل طیفی وزن های مدل مدل و داده

در این پروژه، یک شبکه عصبی چندلایه (MLP) آموزش دیده بر روی دیتاست **Fashion-MNIST** مورد استفاده قرار گرفت. مدل شامل 4 لایه خطی اصلی است که یکی از لایه های میانی ( $512 \rightarrow 512$ ) و لایه نهایی ( $10 \rightarrow 512$ ) برای تحلیل انتخاب شدند.

### تحلیل مقادیر منفرد

با اعمال تجزیه SVD روی ماتریس وزن ها، طیف مقادیر منفرد و واریانس تجمعی آن ها محاسبه شد.

نتایج به دست آمده:

- لایه میانی:


- رتبه لازم برای حفظ ۹۵٪ واریانس: 275
- درصد مقادیر منفرد استفاده شده: 53.71%

- لایه نهایی:

- رتبه لازم برای حفظ ۹۵٪ واریانس: 9
- درصد مقادیر منفرد استفاده شده: 90.00%

### تحلیل

این نتایج نشان می دهند که لایه های میانی دارای افزونگی ساختاری بالاتری هستند و گزینه مناسب تری برای فشرده سازی محسوب می شوند، در حالی که لایه نهایی به دلیل ابعاد کوچکتر، ظرفیت فشرده سازی محدودی دارد.



## **فصل سوم**

### **پیاده سازی عملی فشرده سازی**

## پیاده سازی عملی فشرده سازی

### روش فشرده سازی

لایه خطی انتخاب شده با استفاده از SVD به دو لایه متوالی با رتبه  $k$  جایگزین شد. این کار بدون تغییر عملکرد ریاضی کلی لایه و تنها با یک تقریب کمرتبه انجام گرفت.

#### سناریوهای آزمایشی

مدل در سه حالت بررسی شد:

- بدون فشرده سازی
- فشرده سازی با ۵۰٪ رتبه
- فشرده سازی با ۸۰٪ رتبه

#### دقت اولیه مدل

| حالت مدل        | دقت (%) |
|-----------------|---------|
| بدون فشرده سازی | 86.92   |
| فشرده سازی ۵۰٪  | 86.93   |
| فشرده سازی ۸۰٪  | 86.98   |

نتایج نشان می‌دهد که حتی بدون Fine-tuning، فشرده سازی منجر به افت دقت قابل توجهی نشده است. (در اینجا بهبود یافته، گویا مدل اندکی اورفیت کرده است)

#### مقایسه تعداد پارامترها

| حالت مدل        | تعداد پارامتر |
|-----------------|---------------|
| بدون فشرده سازی | 932362        |
| فشرده سازی ۵۰٪  | 932362        |
| فشرده سازی ۸۰٪  | 774666        |

کاهش محسوس تعداد پارامترها، کارایی حافظه مدل را بهبود می‌دهد.

**فصل چهارم  
ارزیابی دقیق و سرعت**

## ارزیابی دقت و سرعت

### تنظیم دقیق(Fine-tuning)

مدل های فشرده شده به مدت ۳ اپیاک Fine-tune شدند. پس از تنظیم دقیق، دقت ها به شکل زیر بهبود یافت:

| حالت مدل        | دقت بعد از FT (%) |
|-----------------|-------------------|
| بدون فشرده سازی | 86.91             |
| فشرده سازی ۵۰٪  | 88.75             |
| فشرده سازی ۸۰٪  | 88.66             |

این افزایش دقت نشان می دهد که فشرده سازی می تواند به عنوان نوعی منظم سازی (Regularization) عمل کند.

### سرعت استنتاج روی CPU


| حالت مدل        | زمان استنتاج(ms) |
|-----------------|------------------|
| بدون فشرده سازی | 0.29             |
| فشرده سازی ۵۰٪  | 0.30             |
| فشرده سازی ۸۰٪  | 0.26             |

تفاوت زمان ها ناچیز است که نشان می دهد افزایش تعداد لایه ها اثر منفی قابل توجهی بر سرعت CPU در این مقیاس نداشته است.

### نمودار دقت بر حسب نرخ فشرده سازی

نمودار رسم شده نشان می دهد که تا نرخ های بالای فشرده سازی، دقت مدل حفظ شده و حتی پس از افزایش یافته است.

Accuracy vs Compression Rate



## فصل پنجم سوالات تحلیلی

## سوالات تحلیلی

### تأثیر تأخیر ناشی از افزایش تعداد لایه‌ها

در محیط‌هایی مانند GPU ، افزایش تعداد لایه‌های کوچک ممکن است به دلیل parallelism تأثیر کمی داشته باشد، اما در CPU و سیستم‌های embedded ، تأخیر ناشی از فرآخوانی لایه‌ها می‌تواند غالب شود. بنابراین فشرده‌سازی همیشه به افزایش سرعت منجر نمی‌شود و به معماری سخت‌افزار وابسته است.

| توضیح         | تأثیر افزایش محیط |
|---------------|-------------------|
| تعداد لایه‌ها | محیط              |

هر عملیات محاسباتی پشت سر هم انجام می‌شود. افزایش بسیار محسوس CPU تک‌هسته‌ای لایه‌ها با زمان استنتاج (قریباً خطی) رشد می‌کند

پردازش موازی روی هزاران هسته انجام می‌شود، ولی همچنان لایه‌های بزرگ (مثل Conv با فیلترهای زیاد) باعث کمتر محسوس GPU تأخیر می‌شوند.

حتی چند لایه اضافی به دلیل محدودیت حافظه و توان پردازشی می‌تواند زمان استنتاج را به طور قابل توجهی شدید افزایش دهد.

کاهش رتبه یا فشرده‌سازی لایه‌ها می‌تواند تأخیر را کاهش دهد، چون تعداد پارامتر و FLOPs کم می‌شود.

### نقش عدد وضعیت در انتخاب لایه‌های مستعد فشرده‌سازی

عدد وضعیت (Condition Number) معیاری از حساسیت ماتریس نسبت به اغتشاشات است. لایه‌هایی با عدد وضعیت بزرگ و افت سریع مقادیر منفرد، معمولاً افزونگی بالایی دارند و گزینه‌های مناسبی برای فشرده‌سازی کمرتبه محسوب می‌شوند.

**عدد وضعیت (Condition Number)** برای یک ماتریس  $W$  به صورت زیر تعریف می‌شود:

$$\kappa(W) = \frac{\sigma_{\max}}{\sigma_{\min}}$$

ماتریس  $W$  با  $\sigma_{\max}$  و  $\sigma_{\min}$  بزرگترین و کوچکترین مقادیر منفرد هستند. عدد وضعیت نشان می‌دهد که ماتریس تا چه حد «نزدیک به تنزل رتبه» است و چقدر حساس به نویز/خطا است.

**لایه با عدد وضعیت کوچک:**

- مقادیر منفرد بزرگ و کوچک به صورت یکنواخت پخش شده‌اند.
- تقریب رتبه پایین باعث از دست رفتن اطلاعات مهم می‌شود → کمتر مناسب فشرده‌سازی.

**لایه با عدد وضعیت بزرگ:**

- ماتریس دارای چند مقدار منفرد بزرگ و بقیه نزدیک صفر است.
- این لایه مستعد فشرده‌سازی رتبه پایین است، چون می‌توان بیشتر مقادیر کوچک را حذف کرد بدون کاهش دقت مدل.

**فصل ششم  
نتیجه گیری**

## نتیجه گیری

در این پژوهش نشان داده شد که با استفاده از تجزیه رتبه پایین مبتنی بر SVD می‌توان مدل‌های پادگیری عمیق را بدون تغییر معماری کلی، به طور مؤثری فشرده‌سازی کرد. نتایج تجربی حاکی از کاهش تعداد پارامترها، حفظ یا حتی بهبود دقت پس از Fine-tuning ، و عدم افزایش محسوس زمان استنتاج هستند. این رویکرد، راهکاری عملی و صنعتی برای بهینه‌سازی مدل‌های عمیق در محیط‌های با محدودیت منابع محسوب می‌شود.

---

## Abstract

---

## منابع و مراجع

این پروژه نیاز کمی به منابع داشت و بیشتر از دانش خودم استفاده کردم [1]

<https://docs.pytorch.org/> [2]

[https://en.wikipedia.org/wiki/Low-rank\\_approximation](https://en.wikipedia.org/wiki/Low-rank_approximation) [3]

[https://openaccess.thecvf.com/content\\_CVPR\\_2020/papers/Idelbayev\\_Low-Rank\\_Compression\\_of\\_Neural\\_Nets\\_Learning\\_the\\_Rank\\_of\\_Each\\_CVPR\\_2020\\_paper.pdf](https://openaccess.thecvf.com/content_CVPR_2020/papers/Idelbayev_Low-Rank_Compression_of_Neural_Nets_Learning_the_Rank_of_Each_CVPR_2020_paper.pdf) [4]

منابع اصلی درس [5]



**Amirkabir University of Technology  
(Tehran Polytechnic)**

**... Department ...**

**MSc or PhD Thesis**

**Title of Thesis**

**By  
Name**

**Supervisor  
Dr.**

**Advisor  
Dr.**

**Month & Year**